

Part III-B: Deep Learning

Lecture by None

Note by THF

2025 年 3 月 14 日

目录

1	线性代数复习	1
1.1	特殊的矩阵和向量	3
1.2	特征分解	4
1.3	奇异值分解	6
1.4	Moore-Penrose 伪逆	7
1.5	迹	7
1.6	行列式	8
1.7	主成分分析	9

Learn 1

01.28

1 线性代数复习

Definition. 张量：多维数组或多维立方体（二维为矩阵，一维为向量，零维为常量），用字体不同的粗体表示：**A**

对比：矩阵 **A**，张量 **A**

Definition. 向量：一般指列向量，转置后为横向量

Example. $\mathbf{x} = (1, 2, 3)^\top = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$ ，转置后： $\mathbf{x}^\top = \begin{bmatrix} 1 & 2 & 3 \end{bmatrix}$

Definition. 矩阵乘法：左矩阵的行遍历右矩阵的列

Example. 两个向量的点乘（内积）： $\boldsymbol{x} \cdot \boldsymbol{y} = \boldsymbol{x}^\top \boldsymbol{y}$ ，如下图：




图 1: 点积

同理，两个向量的外积： $\boldsymbol{x} \times \boldsymbol{y} = \boldsymbol{x} \boldsymbol{y}^\top$ ，如下图：




图 2: 外积

Definition. 广播：把向量转置后加到矩阵的每一行

Example.

$$\begin{aligned}
 &\boldsymbol{A} && + \boldsymbol{b} && = \boldsymbol{C} \\
 \Rightarrow &\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} && + \begin{bmatrix} b_1 & b_2 & b_3 \end{bmatrix}^\top && = \begin{bmatrix} a_{11} + b_1 & a_{12} + b_2 & a_{13} + b_3 \\ a_{21} + b_1 & a_{22} + b_2 & a_{23} + b_3 \end{bmatrix}.
 \end{aligned}$$

Definition. 范数：曼哈顿距离 \Rightarrow 欧氏距离 $\Rightarrow \dots$, L^p 范数形如：

$$\|\mathbf{x}\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}.$$

Example. 曼哈顿距离： $L^1: \|\mathbf{x}\|_1 = \sum_i |x_i|$, 欧几里得距离： $L^2: \|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$

Learn 2

01.30

Notation. L^2 范数可以写为 $\|\mathbf{x}\|_2$, 也可以简写为 $\|\mathbf{x}\|$

Notation. L^1 范数常用于区分 0 值和距离 0 很近的值, 使用 L^2 范数, 距离太近几乎没有区别

Definition. 最大范数： $p \rightarrow \infty$ 时影响范数的最大因素为最大值：

$$\|\mathbf{x}\|_\infty = \max_i |x_i|.$$

Example. Frobenius 范数： 使用范数衡量矩阵的大小, 类似于 L^2 范数的计算：

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}.$$

Example. 使用范数表示向量的内积：

$$\mathbf{x}^\top \mathbf{y} = \|\mathbf{x}\| \cdot \|\mathbf{y}\| \cos \theta.$$

即：

$$\mathbf{x} \cdot \mathbf{y} = xy \cos \theta.$$

1.1 特殊的矩阵和向量

Example. 对角矩阵, 用 \mathbf{D} 表示, 除主对角线上的元素其他的元素均为零：

$$\mathbf{D} = \begin{bmatrix} a_{1,1} & 0 & \cdots & 0 \\ 0 & a_{2,2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{n,n} \end{bmatrix}.$$

Notation. 对角矩阵不一定是方阵, 非方阵超出方阵的部分全部为 0

Definition. 对角转换 diag : $\text{diag}(\mathbf{v})$ 将 \mathbf{v} 中的元素放入对角矩阵中

对角转换有以下性质:

- $\text{diag}(\mathbf{v})\mathbf{x} = \mathbf{v} \odot \mathbf{x}$
- $\text{diag}(\mathbf{v})^{-1} = \text{diag}\left(\left[\frac{1}{v_1} \quad \dots \quad \frac{1}{v_n}\right]^\top\right)$

Example. 对称矩阵: $\mathbf{A} = \mathbf{A}^\top$, 常用于某些不依赖参数顺序的双参数函数, 交换 i, j 后结果不变

Example. 单位向量: 范数为 1 的向量, 即: $\|\mathbf{x}\|_n = 1$

Example. 向量的正交: $\mathbf{x}^\top \mathbf{y} = 0$, 代表着 $\|\mathbf{x}\|_n$ 和 $\|\mathbf{y}\|_n$ 都不为零时 $\theta = \frac{\pi}{2}$
标准正交: $\theta = \frac{\pi}{2}$ 且 $\|\mathbf{x}\|_n = \|\mathbf{y}\|_n = 1$

Example. 正交矩阵: 行向量和列向量都分别标准正交, 有以下性质:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{A} \mathbf{A}^\top = \mathbf{I} \Rightarrow \mathbf{A}^{-1} = \mathbf{A}^\top.$$

可得: 正交矩阵求逆非常容易, 可以用来求解线性方程组

1.2 特征分解

Definition. 特征向量和特征值:

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

则 λ 为 \mathbf{A} 的特征值, \mathbf{x} 为 \mathbf{A} 的一个 (右) 特征向量

$$\mathbf{x}^\top \mathbf{A} = \lambda \mathbf{x}^\top.$$

称 \mathbf{x} 为左特征向量

Definition. 特征分解: 如果 \mathbf{A} 有 n 个线性无关的特征向量 $\{\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}\}$, 对应 n 个特征值 $\{\lambda_1, \dots, \lambda_n\}$, 将特征向量 (列向量) 排列为一个矩阵 $\mathbf{V} = \begin{bmatrix} \mathbf{v}^{(1)} & \dots & \mathbf{v}^{(n)} \end{bmatrix}$, 并将特征值排列为一个向量 $\boldsymbol{\lambda} = \begin{bmatrix} \lambda_1 & \dots & \lambda_n \end{bmatrix}^\top$, 则:

$$\mathbf{A} = \mathbf{V} \text{diag}(\boldsymbol{\lambda}) \mathbf{V}^{-1}.$$

特征向量、值、分解的性质:

- \mathbf{A} 对 \mathbf{x} 变换相当于对 \mathbf{x} 缩放 λ 倍
- \mathbf{v} 是 \mathbf{A} 的特征向量, 则 $c\mathbf{v}$ 也是, 且特征值一样

- 实对称矩阵一定可以分解为实特征向量和实特征值，即 $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top$

Notation. 实对称矩阵的分解：

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top.$$

其中 \mathbf{Q} 为 \mathbf{A} 的特征向量 $\mathbf{v}^{(i)}$ 组成的正交矩阵， $\mathbf{\Lambda}$ 为对角矩阵，且 $\Lambda_{i,i} = \lambda_i$ 所对应的特征向量是 \mathbf{Q} 的第 i 个列向量 $\mathbf{Q}_{:,i}$

使用 \mathbf{A} 进行矩阵乘法可以看作是：将空间各自沿 $\mathbf{v}^{(i)}$ 延展 λ_i 倍




图 3: 实对称矩阵的乘法

Learn 3

01.31

Notation. $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ 表示二次型或者二次方程 (\mathbf{x} 为二维向量)，如：

$$\begin{aligned} \mathbf{x} &= \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} & \mathbf{A} &= \begin{bmatrix} a & b \\ b & c \end{bmatrix} \\ \mathbf{x}^\top \mathbf{A} \mathbf{x} &= \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} a & b \\ b & c \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= \begin{bmatrix} x_1 a + x_2 b & x_1 b + x_2 c \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &= ax_1^2 + 2bx_1x_2 + cx_2^2. \end{aligned}$$

Definition. 所有特征值都是非负数的矩阵为**半正定**矩阵，对于半正定矩阵有：

$$\forall \mathbf{x}, \mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0.$$

对于正定矩阵 ($A_{i,j} > 0$) 有：

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = 0 \Rightarrow \mathbf{x} = \mathbf{0}.$$

Notation. 当 \mathbf{x} 是 \mathbf{A} 的某个特征向量 \mathbf{v} 时，由于：

$$\mathbf{A} \mathbf{v} = \lambda \mathbf{v}.$$

Learn 3

且 $\mathbf{x} = \mathbf{v} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top$ ，二次型可以写为： $f = \mathbf{v}^\top \mathbf{A} \mathbf{v}$ ，带入得：

$$\begin{aligned} f &= \mathbf{v}^\top \mathbf{A} \mathbf{v} \\ &= \mathbf{v}^\top \lambda \mathbf{v} \\ &= \lambda \mathbf{v}^\top \mathbf{v} \\ &= \lambda (x_1^2 + x_2^2). \end{aligned}$$

如果限定 $\|\mathbf{x}\|_2 = 1$ ，即 $x_1^2 + x_2^2 = 1$ ，则 $f = \lambda$ ，即 $\max(f) = \max(\lambda)$, $\min(f) = \min(\lambda)$

1.3 奇异值分解

除特征分解外，还有一种分解叫做奇异值分解，将一个实对称矩阵分解为**奇异向量**和**奇异值**

Notation. 特征分解： $\mathbf{A} = \mathbf{V} \text{diag}(\boldsymbol{\lambda}) \mathbf{V}^{-1}$

Definition. 奇异值分解 (SVD):

$$\mathbf{A} = \mathbf{U} \mathbf{D} \mathbf{V}^\top \quad \text{or} \quad \mathbf{A} = \mathbf{U} \boldsymbol{\Sigma} \mathbf{V}^\top.$$

Notation. 每个实数矩阵都有一个奇异值分解

Learn 4

02.01

Notation. 奇异值分解出来的部分：

- \mathbf{U} : $m \times m$ 的方阵，为正交矩阵，其列向量为**左奇异向量**
- \mathbf{D} : $m \times n$ 的矩阵，为对角矩阵，其对角线值为**奇异值**
- \mathbf{V} : $n \times n$ 的方阵，为正交矩阵，其列向量为**右奇异向量**

Learn 5

02.18

奇异值分解的各部分来源

假设任意 $m \times n$ 矩阵 \mathbf{A}

1. 求出两个对称矩阵

由于： $(\mathbf{A}^\top \mathbf{A})^\top = \mathbf{A} \mathbf{A}^\top$ ，即这两个矩阵（**方阵**）都是对称的，令 $\mathbf{S}_L : m \times m = \mathbf{A} \mathbf{A}^\top$, $\mathbf{S}_R : n \times n = \mathbf{A}^\top \mathbf{A}$ ，提取出两个对称矩阵的特征向量组：

$$\mathbf{S}_L \Rightarrow \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \dots & \mathbf{u}_m \end{bmatrix} = \mathbf{U} \quad \mathbf{S}_R \Rightarrow \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \end{bmatrix} = \mathbf{V}.$$

如果求出 \mathbf{S}_L 和 \mathbf{S}_R 的特征值，并顺序排列，若 $m > n$ ，则会有： \mathbf{S}_L 的前 n 个特征值与 \mathbf{S}_R 的 n 个特征值一一对应， \mathbf{S}_L 的剩余特征值都为 0

Notation. \mathbf{A} 的非零奇异值的平方是 $\mathbf{A}^\top \mathbf{A}$ 或 $\mathbf{A}\mathbf{A}^\top$ 的特征值

对非 0 的特征值开根号即为奇异值，即： $\lambda_i = \sigma_i^2$

Notation. Σ 中的奇异值为非负值，且按照降序排列，即：

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0.$$

其中：

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r \end{bmatrix}.$$

1.4 Moore-Penrose 伪逆

Learn 6

03.14

简单来说，伪逆是扩展到非方阵的矩阵的逆，正常的逆：

$$\mathbf{A}\mathbf{x} = \mathbf{y} \implies \mathbf{x} = \mathbf{A}^{-1}\mathbf{y}.$$

Definition. 伪逆的定义：

$$\mathbf{A}^+ = \lim_{\alpha \searrow 0} (\mathbf{A}^\top \mathbf{A} + \alpha \mathbf{I})^{-1} \mathbf{A}^\top.$$

实际的计算方法：

$$\mathbf{A}^+ = \mathbf{V}\mathbf{D}^+\mathbf{U}^\top \quad \text{or} \quad \mathbf{A}^+ = \mathbf{V}\Sigma^+\mathbf{U}^\top.$$

其中的矩阵通过 SVD 而得：

$$\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^\top.$$

当 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 中 $m < n$ 时最常用该方法求解线性方程组；当 $m > n$ 时方程组可能没有解，但是伪逆依然可以解出一个 \mathbf{x}_0 ，且这个解最贴合原方程，即：

$$\|\mathbf{A}\mathbf{x}_0 - \mathbf{y}\|_2 = \min \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2.$$

当 $m = n$ 时求解与使用正常逆求解一致。

1.5 迹

Notation. 迹即对角线求和：

$$\text{Tr}\mathbf{A} = \sum_i A_{i,i}.$$

Learn 6

迹运算可以用来表示 Frobenius 范数。回顾 Frobenius 范数：

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}.$$

设 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ，由于：

$$\begin{aligned} \mathbf{A}\mathbf{A}^\top &= \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1n} \\ A_{21} & \ddots & & \\ \vdots & & \ddots & \\ A_{m1} & & & A_{mn} \end{bmatrix} \begin{bmatrix} A_{11} & A_{21} & \cdots & A_{m1} \\ A_{12} & \ddots & & \\ \vdots & & \ddots & \\ A_{1n} & & & A_{mn} \end{bmatrix} \\ &= \begin{bmatrix} A_{11}^2 + A_{12}^2 + \cdots + A_{1n}^2 & & & \\ & A_{21}^2 + A_{22}^2 + \cdots + A_{2n}^2 & & \\ & & \ddots & \\ & & & A_{m1}^2 + A_{m2}^2 + \cdots + A_{mn}^2 \end{bmatrix} \\ &\implies \text{Tr}\mathbf{A} = \sum_i \sum_j A_{ij}^2. \end{aligned}$$

Notation. 迹运算的性质：**轮换对称**，即：

$$\text{Tr}(\mathbf{A}\mathbf{B}\mathbf{C}) = \text{Tr}(\mathbf{C}\mathbf{A}\mathbf{B}) = \text{Tr}(\mathbf{B}\mathbf{C}\mathbf{A}).$$

并且如果矩阵的形状改变，如 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{B} \in \mathbb{R}^{n \times m}$ ，相乘后 $\mathbf{AB} \in \mathbb{R}^{m \times m}$ 而 $\mathbf{BA} \in \mathbb{R}^{n \times n}$ ，但是 $\text{Tr}(\mathbf{AB}) = \text{Tr}(\mathbf{BA})$ 仍然成立。

拓展到多个矩阵相乘：

$$\text{Tr}\left(\prod_{i=1}^n \mathbf{F}^{(i)}\right) = \text{Tr}\left(\mathbf{F}^{(n)} \prod_{i=1}^{n-1} \mathbf{F}^{(i)}\right).$$

Notation.

$$a = \text{Tr}(a).$$

1.6 行列式

代表一个矩阵内列向量围成的空间大小，如：

$$\mathbf{A} \in \mathbb{R}^{2 \times 2} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}.$$

代表二维空间中由 $\begin{bmatrix} A_{11} & A_{21} \end{bmatrix}^\top$ 和 $\begin{bmatrix} A_{12} & A_{22} \end{bmatrix}^\top$ 所围成的空间大小（所围成的平行四边形大小）

Notation. 如果行列式为 0，说明该线性空间至少朝一个维度坍塌了（3 维 \rightarrow 2 维 \sim 0 维）

1.7 主成分分析

假设有一组二维数据，这些数据有一个比较明显的走向，因此我们希望将这个明显的走向体现出来，而忽略其他的部分来实现数据的压缩。通过找到数据中心并旋转坐标系来拟合一个损失最小的坍塌方向。




图 4: 主成分分析图示

其中， x' 为数据的主成分