

Part III-B: Medicine AI

Lecture by None

Note by THF

2025 年 3 月 8 日

目录

0.1 回归	1
--------	---

Learn 9

03.06

0.1 回归

简单来说，回归通过一系列**离散**的点，估计出一个**连续**的关系。回归的种类：

- 线性回归：使用线性函数 $f(x_i) = wx_i + b$
- 对数几率回归：本质是一种分类算法，通过引入 sigmoid 函数来确定哪些数据被激活
- 多项式回归：通过 $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n + \varepsilon$ 来拟合数据
- 岭回归
- 套索回归
- ...

sigmoid 函数：

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

图像如下：

这个函数对应的回归模型为：

$$P(y = 1 \mid \mathbf{x}) = \sigma(\boldsymbol{\theta}^\top \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^\top \mathbf{x}}}$$

$$P(y = 0 \mid \mathbf{x}) = 1 - P(y = 1 \mid \mathbf{x}).$$

首先来看线性回归，有一个数据集如下：

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}.$$




图 1: sigmoid 函数

其中集合中元素的第一个参数为一个 m 维向量，即：

$$\mathbf{x}_i = \begin{bmatrix} x_i^{(1)} & x_i^{(2)} & x_i^{(3)} & \dots & x_i^{(m)} \end{bmatrix}^\top.$$

首先考虑一维向量，即常数，这个计算就是常见的线性回归计算，使用最小二乘法，求出 w, b 并拟合为以下表达式：

$$f(x_i) = wx_i + b.$$

如果输入为多维向量，如三维向量，那么由于向量需要通过点乘得到常数，因此 w 成为一个向量，即：

$$f(\mathbf{x}_i) = \mathbf{w}^\top \mathbf{x}_i + b + \varepsilon_i.$$

这里有一个误差项，表示回归所不能解释的部分（常常看作一个 $\mathbb{E}_{\varepsilon_i \sim p} = 0$ 的高斯噪声），一般不考虑，因此也写为：

$$f(\mathbf{x}_i) \approx \mathbf{w}^\top \mathbf{x}_i + b.$$

归类到多维后，称 $\mathbf{w} \in \mathbb{R}^m$ 为模型的**权重向量**。回归中常用 MSE 来评价性能，求解 \mathbf{w} 和 b 一般使用**最小二乘法**，过程如下：

证明。回顾残差平方和：

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

把 \hat{y}_i 换为 $f(\mathbf{x}_i)$ 写出这个回归的均方误差表达：

$$E_{(\mathbf{w}, b)} = \arg \min_{(\mathbf{w}, b)} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 = \arg \min_{(\mathbf{w}, b)} \sum_{i=1}^m (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2 \quad (1)$$

这里 $\arg \min$ 的意思是通过取一组 \mathbf{w}, b 的值使得表达式最小，严格定义上，这个式子所代表的过程就称为线性回归。求一个二元函数 $E_{(\mathbf{w}, b)} = \sum_{i=1}^m (\mathbf{w}^\top \mathbf{x}_i + b - y_i)^2$ 的最小值，由于向量内积的性质 $\mathbf{w}^\top \mathbf{x}_i = \mathbf{x}_i^\top \mathbf{w}$ 也可以写为：

$$E = \sum_{i=1}^m (\mathbf{x}_i^\top \mathbf{w} + b - y_i)^2.$$

这个式子可以直接求偏导来计算最小值，但是为了机器运算方便，尽量转化为矩阵运算。平方和很容易让人想到 L^2 范数，或者 Frobenius 范数。观察可得，这里的平方和可以拆成 y 和 $\mathbf{x}_i^\top \mathbf{w} + b$ 两部分。记住 \mathbf{x}_i 和 \mathbf{w} 都是列向量，这里为了统一输入，即输入的矩阵不含变量，给每一个 \mathbf{x}_i 的末端加上一个 1，给 \mathbf{w} 的末端加上一个 b ，这样做之后两个向量变成下列形式：

$$\tilde{\mathbf{x}}_i = \begin{bmatrix} \mathbf{x}_i^\top & 1 \end{bmatrix}^\top = \begin{bmatrix} x_i^{(1)} \\ x_i^{(2)} \\ \vdots \\ x_i^{(n)} \\ 1 \end{bmatrix}$$

$$\tilde{\mathbf{w}} = \begin{bmatrix} \mathbf{w}^\top & b \end{bmatrix}^\top = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \\ b \end{bmatrix}.$$

将所有的 $\tilde{\mathbf{x}}_i$ 横向合并，记为 \mathbf{X} ，形如：

$$\mathbf{X} = \begin{bmatrix} \tilde{\mathbf{x}}_1^\top \\ \tilde{\mathbf{x}}_2^\top \\ \vdots \\ \tilde{\mathbf{x}}_m^\top \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1^\top & 1 \\ \mathbf{x}_2^\top & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^\top & 1 \end{bmatrix} \quad \mathbf{X} \in \mathbb{R}^{m \times (n+1)}.$$

带回 $E_{(\mathbf{w}, b)}$ 后可以把两个参数整合为一个，同时由于所有的 $\tilde{\mathbf{x}}_i$ 在 \mathbf{X} 中，计算发现：

$$E_{\tilde{\mathbf{w}}} = (\mathbf{X}\tilde{\mathbf{w}} - \mathbf{y})^2 = \|\mathbf{y} - \mathbf{X}\tilde{\mathbf{w}}\|_2^2.$$

想要求一个函数的最小值还可以用梯度法，即 $\nabla f = 0$ 时 f 可能取得一个极值（在这里就是求导），对于 $E_{\tilde{\mathbf{w}}}$ ，对 $\tilde{\mathbf{w}}$ 求梯度：

$$\nabla_{\tilde{\mathbf{w}}} E_{(\tilde{\mathbf{w}})} = \frac{\partial E_{\tilde{\mathbf{w}}}}{\partial \tilde{\mathbf{w}}}.$$

这里有一些小细节，首先将 E 展开为内积形式：

$$\begin{aligned} E &= (\mathbf{y} - \mathbf{X}\tilde{\mathbf{w}})^\top (\mathbf{y} - \mathbf{X}\tilde{\mathbf{w}}) = (\mathbf{y}^\top - \tilde{\mathbf{w}}^\top \mathbf{X}^\top) (\mathbf{y} - \mathbf{X}\tilde{\mathbf{w}}) \\ &= \mathbf{y}^\top \mathbf{y} - 2\tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{y} + \tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{X} \tilde{\mathbf{w}}. \end{aligned}$$

此处注意： $2\tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{y}$ 是一个标量，因此对其求转置仍为其本身，即：

$$\begin{aligned} E &= \mathbf{y}^\top \mathbf{y} - 2\tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{y} + \tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{X} \tilde{\mathbf{w}} \\ &= \mathbf{y}^\top \mathbf{y} - 2\mathbf{y}^\top \tilde{\mathbf{w}} \mathbf{X} + \tilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{X} \tilde{\mathbf{w}}. \end{aligned}$$

引入两个对矩阵求导的公式：

$$\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^\top \mathbf{A} = \mathbf{A}^\top \quad (2)$$

$$\frac{\partial}{\partial \mathbf{x}} \mathbf{x}^\top \mathbf{A} \mathbf{x} = 2\mathbf{A}\mathbf{x} \text{ (对称矩阵)} \quad (3)$$

对于第一个公式，令 $\mathbf{A} = \mathbf{X}^\top \mathbf{y}$ ，可以解得

$$\frac{\partial}{\partial \widetilde{\mathbf{w}}} 2\widetilde{\mathbf{w}}^\top \mathbf{X}^\top \mathbf{y} = .$$

对于

□

Learn 10

03.08